一页结论 · 同一批财报：什么该建库，什么该微调

方向 B | 微导纳米（688147）· 7 份财报 1329 页 · Qwen2.5-1.5B-Instruct + LoRA（Colab T4，3 epoch，104 条问答）

一句话结论：「董秘口径」可以微调进去，「董秘知道的事」调不进去。同一批财报里，凡是「公司这个数是多少」的事实题，该建库检索（RAG）；凡是「怎么把结论讲得像董秘」的口径与格式，才值得微调。本次微调把引文格式率从 7.5% 拉到 72~92%，但事实答对率只有 10~33%，连训练时见过的题也只有 16.3%。

四格对照（真实数字）

方案	样本	答对率	写了真实页码	引用页码正确	有引文率
微调后 · 训练事实 · 原问法	104	**16.3%**	88.5%	0.0%	82.7%
微调后 · 训练事实 · 换问法	104	**10.6%**	92.3%	0.0%	81.7%
微调后 · 未见事实 · 原问法	40	**32.5%**	85.0%	0.0%	72.5%
微调后 · 未见事实 · 换问法	40	**20.0%**	87.5%	0.0%	72.5%
A 基线：BM25 检索 + 同一基座（不训练）· 未见事实	40	**50.0%**	22.5%	0.0%	7.5%

「答对」= 参考答案关键数字命中 ≥60%；没有可比数字的题（占 46%）退化为 8 字片段重合。

为什么「引用页码正确」全是 0%（这一列不能当 bug 看掉）：微调后 85~92% 的回答都写了页码，格式学对了；但页码塌缩成两个数 —— 第 39 页被引用 49 次、第 10 页 21 次，正好是训练集里出现最频繁的两页。它学会的是「这里该写一个页码」，不是「这句话出自哪一页」。基线那边 25% 是照抄了提示词里的「第 X 页」占位符（新版已改），另 52.5% 干脆没用这个格式。

三个发现

① SFT 学会的是「口径」，不是「事实」

微调后 72~92% 的回答写出了「」引文和「依据：[报告 第 N 页]」，而同一基座靠检索作答时只有 7.5% 会引原文。但按数字严格判，训练事实上 208 次作答里只有 1 次把关键数字说对 —— 格式和内化是两件事。

② 连「教过的」也没背牢：188 条引错页码

训练时见过的问题，模型仍把 2022 年报的问题答成「2025 年半年报 第 39 页」，把 241 名研发人员答成「2025 年 3 月 31 日 91 人」。这正是课件说的「背诵的天性」：数字型事实最容易背串。

③ 事实类问题，检索比微调更划算

同样的 1.5B 基座，给它 BM25 检索来的 3 块原文，未见事实答对率 50%；微调后只有 20~32.5%，且它引用的页码几乎都不是正确那一页。事实要被「递进窗口」，不是「写进权重」。

为什么没复现课件第 113 页的「2%→100%」

课件的实验是 421 条问答、答案短、6 轮；我们是 104 条、答案长（3~5 句 + 引文）、3 轮。这是样本量与容量的边界，不是方法的边界 —— 想靠 SFT 记住财报事实，成本会随页数线性上涨；而事实本来就在报告里，检索一次几乎免费。

限制（写清楚比好看重要）

- 样本只有 104 条（课件那场是 421 条）、答案又是 3~5 句带引文的长文本、只训 3 轮 r=16 —— 课件参数扫描显示这类配置 loss 降得快、但「未见片段」几乎不涨。
- 判分有两套口径：数字命中（严格，要求命中 ≥60%）与 8 字片段重合（宽松）。数字题占 46%，宽松口径会把「说得像」也算对，所以两个数要一起看。
- 提示词里写了「第 X 页」这种占位符，基线模型有 25% 直接照抄；新版 notebook 已改成「写真实页码」。

回到我的案例（人才引进 → 技术进步 → 创新成果）

训练集里最密集的正是这条线：股权激励的授予与归属条件、研发人员数量与占比、研发投入的投向、专利与产业化进展。微调后的模型没把这些数字记准，但学会了董秘的答法 —— 先给结论、再引原文、最后标出处。这套答法可以直接搬进案例写作：每写一条判断都能指回报告第几页；具体数字回到 kb.jsonl 的 2219 块里检索。